

## OPENWIKI COMPLETE TECHNICAL SPECIFICATION

# KV-Cache 최적화 기술 비교 평가 OpenWiki 종합 기술 백서

## KIVI(SW) vs CXL-PNM(HW) · LangGraph 오케스트레이션 · 2단계 Fast-Fail 검증 · Dual TRL 프레임워크

본 백서는 대규모 언어 모델(LLM) 서빙 환경의 핵심 메모리 병목인 KV 캐시를 최적화하는 대표 기술 KIVI(소프트웨어 비대칭 2-bit 양자화)와 CXL-PNM(하드웨어 CXL 근접 연산 가속)을 객관적·체계적으로 비교 분석하기 위해 구축된 LangGraph 기반 멀티 에이전트 평가 시스템의 OpenWiki 증거 기반 인덱스를 집대성한 종합 아키텍처 명세서입니다.

LangGraph 1.2.12

StateGraph

Agentic RAG

FAISS

Tavily Search

Fast-Fail Audit

Dual TRL

KIVI

CXL-PNM

xhtml2pdf

## PREPARED BY &amp; SYSTEM ARCHITECTURE

SKALA 4기 판교 9반 3팀 (강건호, 김호민, 윤영민, 전경호, 정은  
희, 최지윤)

"Rigorous Evidence-Based Multi-Agent Evaluation Without  
Confirmation Bias."

## 00 총괄 요약 및 인터랙티브 목차

### ■ 멀티 에이전트 평가 프레임워크 핵심 설계 철학

본 시스템은 단순히 LLM의 생성 능력에 의존하지 않고, 논문 원문 **Agentic RAG(학술 증거)**와 **Tavily 실시간 웹 검색(시장 및 4대 이해관계자)**을 병렬 교차 수집한 뒤, **2단계 Fast-Fail 근거 검증기(규칙 R1~R4 및 LLM 판사 R5)**를 통해 편향과 환각을 원천 차단합니다. 최종적으로 기술 준비도(TRL)를 개별 기술과 생태계 차원으로 이원화하여 산출하는 엔터프라이즈급 평가 파이프라인을 제공합니다.

#### Agentic Evidence Pipeline (Part I & II)

KIVI 및 CXL-PNM 원문 논문 토큰 바운딩 청킹, FAISS 로컬 벡터 색인, 20개 질의 임베딩 벤치마크, 지지/반박 쌍 검색 기반 시장성 및 4대 액터(운영자·개발자·유저·공급자) 다각도 리서치.

#### Audit, Synthesis & Delivery (Part III & IV)

결정론적 정적 4대 규칙과 LLM 판사(gpt-4o)의 이중 필터링, 에이전트당 최대 2회 표적 재시도, Dual TRL(연구 vs 도입) 산출, Jinja2 마크다운 조립 및 한글 지원 PDF 자동 내보내기.

**14개**

전역 STATE 계약 키

**6개**

오케스트레이션 노드

**2단계**

FAST-FAIL 품질 감사

**Hit@5 0.80**

E5 임베딩 벤치마크

### ■ Interactive Table of Contents

#### PART I. FOUNDATION & RUNTIME ORCHESTRATION

01. 프로젝트 개요 및 런타임 환경 구축 (quickstart.md) ..... P. 03
02. LangGraph 런타임 오케스트레이션 및 토폴로지 (orchestration.md) ..... P. 04

#### PART II. STATE SCHEMA & RETRIEVAL INTEGRATIONS

03. 상태 스키마 및 2단계 출처 보증 계약 (state-and-evidence.md) ..... P. 05
04. 논문 Agentic RAG 및 임베딩 벤치마크 (paper-rag.md) ..... P. 06

#### PART III. WEB RESEARCH & QUALITY AUDIT

05. Tavily 시장성 및 4대 이해관계자 웹 리서치 (web-research.md) ..... P. 07
06. 2단계 Fast-Fail 품질 감사 및 표적 재시도 (evidence-audit.md) ..... P. 08

#### PART IV. SYNTHESIS, OPERATIONS & VERIFICATION

07. Dual TRL 성숙도 합성 및 리포트 전달 체계 (synthesis.md) ..... P. 09
08. 테스트 전략, 안전 변경 경계 및 운영 관리 (test-strategy.md) ..... P. 10

## 01 프로젝트 개요 및 런타임 환경 구축

### ■ 평가 대상 기술 선정 배경 및 무승자 원칙

본 시스템은 동일한 클라우드 LLM 서버 KV 캐시 병목에 대해 대칭적인 해법을 제시하는 **KIVI**(소프트웨어 비대칭 2-bit 양자화, ICML 2024)와 **CXL-PNM**(하드웨어 CXL 메모리 내 근접 연산, PACT 2025)을 비교 평가합니다. 시스템은 특정 기술을 우열로 재단하지 않고, 워크로드 조건(배치 크기, 문맥 길이, 인프라 비용)에 따른 장단점과 미검증 증거 공백(Evidence Gap)을 충실히 밝힙니다.



### ■ 런타임 설치 및 환경 변수 계약

| 환경 변수                | 필수 여부 | 기본/예시 값  | 역할 및 미설정 시 Fallback 동작                                                    |
|----------------------|-------|----------|---------------------------------------------------------------------------|
| OPENAI_API_KEY       | 권장    | sk-...   | R5 LLM 판사(gpt-4o), 보고서 정제(gpt-4o), RAG 질의 요약에 사용. 미설정 시 Mock/Fallback 전환. |
| TAVILY_API_KEY       | 권장    | tvly-... | 시장성 및 4대 액터 웹 실시간 검색. 미설정 시 검색 없이 진행되며 관련 주장은 <b>insufficient</b> 로 격리.   |
| LANGCHAIN_TRACING_V2 | 선택    | true     | LangSmith 멀티 에이전트 실행 추적 및 노드 간 State 전이 모니터링 활성화.                         |
| HF_TOKEN             | 선택    | hf-...   | HuggingFace 임베딩 모델(intfloat/e5-small-v2) 다운로드 속도 향상 및 Rate Limit 완화.      |

### ■ 주요 실행 및 운영 명령어

#### TERMINAL | EXECUTION CONTRACTS

BASH

```
# 1. 의존성 설치 및 가상환경 활성화 (Python 3.10+)
uv venv && source .venv/bin/activate && uv pip install -r requirements.txt

# 2. 논문 PDF 색인 구축 및 임베딩 벤치마크 평가 (Hit@5, MRR)
python -m src.rag.indexer      # data/papers/*.pdf -> data/faiss_index/
python -m src.rag.benchmark    # data/eval_queries.json 기반 평가 및 채택


# 3. CLI 배치 파이프라인 실행 (최종 평가 보고서 Markdown 및 PDF 생성)
python main.py                # final_evaluation_report.md 및 .pdf 산출

# 4. Streamlit 인터랙티브 대시보드 실행 (선택 설치)
uv pip install streamlit && streamlit run app.py
```

## 02 LangGraph 런타임 오케스트레이션 및 토폴로지

### ■ StateGraph 기반 6개 노드 파이프라인과 타깃 피드백 제어

런타임 그래프는 `OverallState`를 공유하는 LangGraph `StateGraph`로 조립됩니다. 두 개의 초기 병렬 브랜치(논문 RAG와 시장 리서치)로 시작하며, 시장 결과 컨텍스트가 이해관계자 노드로 순차 체이닝된 후, `evidence_audit`에서 팬인(Fan-in)되어 엄격한 품질 감사를 거칩니다.



### ■ 6대 전용 노드 역할 및 State 소유권 계약

| 노드 명칭                             | 담당   | 전담 출력 State 키                                  | 주요 역할 및 동작 메커니즘                                         |
|-----------------------------------|------|------------------------------------------------|---------------------------------------------------------|
| <code>paper_analysis</code>       | 담당 B | <code>tech_sw, tech_hw, domain, claims</code>  | KIVI/CXL-PNM 논문 원문 RAG 검색, 수차-메커니즘 추출, 연구 TRL 근거 기록.    |
| <code>market_research</code>      | 담당 C | <code>market, claims, sources</code>           | 기술 계열별 채택·배포·생태계·도입장벽 웹 조사, 채택 TRL(MAT-A) 근거 기록.        |
| <code>stakeholder_research</code> | 담당 C | <code>stakeholder, claims, sources</code>      | 시장 컨텍스트(key_vendors)를 체이닝하여 4대 액터 영향도 및 지지/반박 조사.       |
| <code>evidence_audit</code>       | 담당 D | <code>audit, retry_count, claims.status</code> | 정적 4대 룰 및 LLM 판사 사실성 검증, 결함 에이전트 표적 피드백(최대 2회).         |
| <code>evaluation_synthesis</code> | 담당 E | <code>trl, synthesis</code>                    | 검증 완료된 Claim 기반 개별 기술 TRL과 계열 산업 TRL 이원화 도출.            |
| <code>report_generation</code>    | 담당 E | <code>report</code>                            | Jinja2 템플릿 골격 조립, 인용 번호 부여 및 엄격한 윤문 (Strict Grounding). |

### ■ 감사 팬인 및 조건부 표적 라우팅 불변식

- **시장-이해관계자 종속성 보존:** `market` 이슈 발생 시 `market_research`로 라우팅되며, 일반 엣지를 통해 `stakeholder_research`가 반드시 연쇄 재실행되어 컨텍스트 최신성을 유지합니다.
- **논문 단독 재시도 단축 경로:** 논문 단독 이슈 시 `paper_analysis` 실행 후 즉시 `evidence_audit`으로 복귀하며, 타 에이전트와 동시 재시도 시에는 중복 감사를 방지하기 위해 단일 팬인 경로로 통합됩니다.
- **루프 수렴 및 무한 루프 차단:** 이슈가 없거나, 모든 관련 에이전트의 `retry_count`가 상한선(2회)에 도달하면 무조건 `evaluation_synthesis`로 전이하여 안전하게 종료합니다.

### 03 상태 스키마 및 2단계 출처 보증(Provenance) 계약

#### OverallState 14개 필드와 2단계 데이터 출처 모델

파이프라인 전체가 공유하는 **OverallState**는 14개의 전역 키로 구성됩니다. 단순한 결과 저장을 넘어 **Claim(주장) → Evidence(스니펫) → Source(원천 출처)**로 이어지는 엄격한 2단계 출처 보증 모델을 구현하여 모든 평가 수치와 주장의 출처를 역추적할 수 있습니다.

#### OverallState 14개 전역 키 구조

- selected**: 비교 대상 기술군 정의
- tech\_sw, tech\_hw, domain**: 논문 분석 메트릭
- market**: 시장 도입·생태계·벤더 요약
- stakeholder**: 4대 액터 분석 요약
- claims, evidence, sources**: 리듀서 적용 컬렉션
- audit, retry\_count**: 감사 결합 및 재시도 상태
- trl, synthesis, report**: 최종 평가 산출물

#### 2단계 출처 추적 (Provenance Model)

- Claim**: 고유 ID(DOM-\*, MKT-\*, STK-\*), 유형(fact, vendor\_claim, simulation), 상태(ok, flagged, insufficient, rejected)
- Evidence**: **evidence\_id**, **source\_id**, 원문 텍스트 스니펫
- Source**: **source\_id**, URL, 신뢰도 등급(T1~T4), 제목, 날짜
- 핵심 이점**: 출처 신뢰 등급 감사 및 참고문헌 자동 링크

#### 역등적 커스텀 리듀서(Reducer) 동작 원리

| 리듀서 함수                       | 적용 필드                          | 식별 기준                    | 역등성 보장 및 병합 정책                                                           |
|------------------------------|--------------------------------|--------------------------|--------------------------------------------------------------------------|
| <code>upsert_claims</code>   | <code>state["claims"]</code>   | <code>claim.id</code>    | 동일 Claim ID 유입 시 기존 레코드를 완전히 대체 (Replace). 신규 ID는 추가. 재시도 시 역등성 유지.      |
| <code>upsert_evidence</code> | <code>state["evidence"]</code> | <code>evidence_id</code> | 동일 Evidence ID 유입 시 최신 정제 스니펫으로 대체. 중복 축적 방지.                            |
| <code>union_sources</code>   | <code>state["sources"]</code>  | <code>url</code> 정규화     | 동일 URL 유입 시 기존 canonical source_id를 보존하고 중복 제거. Evidence의 외래키 참조 무결성 유지. |

#### Claim ID 소유권 및 라우팅 규칙

- DOM-\*** 및 **MAT-R\*** (연구 성숙도): `paper_analysis` 노드가 단독 소유하며, 논문 원문 근거만 허용.
- MKT-\*** 및 **MAT-A\*** (채택 성숙도): `market_research` 노드가 소유하며, 시장 검색 결과에서 MAT-A 파생.
- STK-01 ~ STK-08**: `stakeholder_research` 노드가 소유하며, 4대 액터 × 2개 기술 계열을 매핑.
- 참조 무결성 보장**: 조사 노드는 `resolve_source_id`를 사전 호출하여 이미 존재하는 동일 URL의 canonical ID를 재사용함으로써 `union_sources` 시 발생하는 외래키 단절을 원천 방지합니다.

## 04 논문 Agentic RAG 파이프라인 및 임베딩 벤치마크

### 정밀 청킹, 충분성 게이트 및 모델 벤치마크

논문 증거 수집은 KIVI와 CXL-PNM 신뢰 PDF 원문으로부터 출발합니다. 400~480 토큰 경계의 섹션 인지형 청킹과 FAISS 로컬 벡터 색인을 구축하고, 20개 코퍼스 질의 벤치마크를 통해 **Hit@5 ≥ 0.8** 을 충족하는 최적 임베딩 모델(intfloat/e5-small-v2)을 채택했습니다.

#### 섹션 인지형 청킹 (Section-aware Chunking)

- PyPDFLoader 기반 논문 파싱 및 기술 태깅
- Abstract, 번호 매겨진 섹션, References 경계 복원
- 헤더, 페이지 번호, arXiv 각주, KIVI 소속 각주 제거
- 400~480 토큰 경계 유지 및 72 토큰 연속 오버랩 적용

#### Agentic RAG 충분성 게이트 (Sufficiency Gate)

- filter={"tech": tech} 메타데이터 기술 격리 검색
- 후보 청크별 LLM YES/NO 직접 응답 충분성 판정
- 엄격한 제약:** 대역폭 질문에 처리량 수치 연결 금지
- 연속 1~3문장 원문 그대로 발체(Contiguous Quotation)

### 임베딩 모델 정량 벤치마크 평가 결과

| 임베딩 모델 명칭              | 파라미터 | Hit@5 | MRR    | Hit@5 ≥ 0.8 | 최종 결과          |
|------------------------|------|-------|--------|-------------|----------------|
| BAAI/bge-small-en-v1.5 | 33M  | 0.75  | 0.5480 | 미달          | 탈락             |
| intfloat/e5-small-v2   | 33M  | 0.80  | 0.5955 | 충족          | 최종 채택          |
| BAAI/bge-m3            | 568M | —     | —      | —           | 소형 모델 충족으로 미측정 |

### 축 보존 쿼리 재작성 및 복수 청크 결합

SRC/RAG/AGENTIC\_RAG.PY | AXIS PRESERVATION &amp; MULTI-CHUNK

PYTHON

```
# 1. 평가 축 보존 쿼리 재작성 (최대 2회)
def _preserves_axis(original_query, rewritten_query, axis_terms):
    # 재작성 쿼리가 원래 평가 축(대역폭, 메모리 등) 용어를 포함하는지 검증
    return any(term in rewritten_query.lower() for term in axis_terms)

# 2. CXL-PNM 연구 성숙도(MAT-R02) 2개 청크 결합 검증
# 시뮬레이터 환경 청크 + 워크로드/모델 청크를 동시에 확인하여 완전한 실험 조건 확보
if match_simulator_chunk and match_workload_chunk:
    evidence = join_verbatim_sentences(chunk1, chunk2)
    claim.kind = "simulation" # 실측이 아닌 사이클 단위 시뮬레이션 명시
```

## 05 Tavily 시장 및 4대 이해관계자 웹 리서치

### ■ 확증 편향 방지를 위한 지지(Support)·반박(Counter) 쌍 검색

외부 웹 리서치 노드는 각 평가 항목마다 **지지 쿼리(최대 3건)**와 **반박 쿼리(최대 2건)**를 반드시 쌍(Pair)으로 실행합니다. 반박 근거가 없는 경우

**counter-evidence not found** 로 명시하며, 결코 인위적인 결론을 지어내지 않습니다.

### 출처 신뢰도 4단계 티어링 (Tier 1 ~ Tier 4)

- **T1**: 학술 논문 및 공식 표준 (arXiv, IEEE, ACM, CXL Consortium)
- **T2**: 주요 하드웨어/클라우드 벤더 도메인 (Samsung, SK Hynix, Intel, NVIDIA)
- **T3**: 공신력 있는 일반 웹 언론사 및 테크 퍼블리셔
- **T4**: 개인 블로그, 소셜 미디어, 커뮤니티 (단독 근거 채택 엄격 금지)

### 주장 유형(Kind) 보수적 자동 분류

- **vendor\_claim**: T2 벤더사 공식 발표 자료 (독립 사실과 엄격 분리)
- **estimate**: CAGR, 전망치, 미래 예측 단어가 포함된 시장 지표
- **simulation**: 하드웨어 논문 내 사이클 단위 시뮬레이션 지표
- **fact**: 객관적 검증이 완료된 학술/산업계 실측 데이터

### ■ 4대 이해관계자(Actor) × 기술 계열 교차 분석 매트릭스

| 이해관계자 (Actor)                           | KIVI (소프트웨어 2-bit KV 양자화)                                                                               | CXL-PNM (하드웨어 메모리 확장 및 근접연산)                                                                           |
|-----------------------------------------|---------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------|
| 클라우드 서버 운영자<br>(Cloud Serving Operator) | <b>이점</b> : 기존 GPU 인프라 그대로 적용, 최대 2.6배 메모리 절감.<br><b>우려</b> : 복잡한 양자화 커널 운영 위험 및 장기 문맥 품질 저하.           | <b>이점</b> : CXL 풀링으로 메모리 용량 한계 극복, GPU recall 제거.<br><b>우려</b> : 신규 하드웨어 도입 비용(CAPEX) 및 상용화 지연.        |
| 프레임워크 개발자<br>(Framework Developer)      | <b>이점</b> : vLLM 등 오픈소스 서버 프레임워크와의 소프트웨어적 통합 용이.<br><b>우려</b> : PagedAttention 등 최신 메모리 관리 기법과의 호환성 유지. | <b>이점</b> : 드라이버 레벨 메모리 매핑 지원 시 투명한 확장 가능.<br><b>우려</b> : PNM 전용 커스텀 지시어 및 독자 SDK 통제인 종속성.             |
| 엔드 유저 (End User)                        | <b>이점</b> : 동시 사용자 수 증가에 따른 토큰 생성 지연 및 비용 완화.<br><b>우려</b> : 2-bit 양자화로 인한 미세한 출력 품질/정확도 하락 가능성.        | <b>이점</b> : 초대형 문맥 질의 시에도 일관된 응답 속도 및 품질 유지.<br><b>우려</b> : 인프라 원가 상승이 최종 서비스 가격에 전가될 위험.              |
| HW/메모리 공급사<br>(HW/Memory Supplier)      | <b>시장 관점</b> : GPU 메모리 부족 문제를 완화하여 기존 HBM 판매를 보완.<br><b>한계</b> : 추가적인 메모리 칩 판매 촉진 효과는 제한적.              | <b>시장 관점</b> : CXL 기반 DRAM 및 PNM 가속기 신규 고부가가치 시장 창출.<br><b>장벽</b> : CXL 2.0/3.0 생태계 성숙도 및 표준 채택 주기 의존. |


### ■ 시장 컨텍스트 체이닝 및 벤더 주입

**market\_research** 에서 추출된 실제 시장 진출 벤더(**market["key\_vendors"]**)는 **stakeholder\_research** 의 질의 생성 시 **{vendor}** 슬롯으로 자동 전달됩니다. CXL-PNM은 Samsung, SK Hynix, Intel을 우선 참조하고, KIVI는 NVIDIA를 참조하여 현실적인 생태계 조사를 보장합니다.

## 06 2단계 Fast-Fail 품질 감사 및 표적 재시도

### ■ 결정론적 정적 룰(R1~R4)과 LLM 판사(R5)의 이중 필터링 체계

증거 감사는 병렬 수집된 연구 데이터와 최종 종합 분석 사이의 **품질 통제 게이트**입니다. 비용과 지연시간을 줄이기 위해 먼저 4대 정적 규칙을 무호출로 실행하여 결함을 걸러내고, 이를 통과한 정상 주장에 대해서만 고비용의 LLM 판사(gpt-4o)를 실행합니다.



### ■ 5대 감사 검증 규칙 명세

| 규칙 ID | 검증 방식           | 검증 조건 및 결함 정의                                                    | 발행 조치 (Action)                       | 한도 도달 시 상태                |
|-------|-----------------|------------------------------------------------------------------|--------------------------------------|---------------------------|
| R1    | 정적 (Static)     | <code>kind="fact"</code> 주장에 연결된 <code>evidence_ids</code> 가 누락됨 | <code>search_evidence</code>         | <code>insufficient</code> |
| R2    | 정적 (Static)     | 인용된 출처가 모두 T4(블로그/SNS)이거나 출처 불명확                                 | <code>search_evidence</code>         | <code>insufficient</code> |
| R3    | 정적 (Static)     | 시장/이해관계자/MAT-A 주장에 반박 검색이 누락됨                                    | <code>search_counter_evidence</code> | <code>insufficient</code> |
| R4    | 정적 (Static)     | CXL-PNM 논문 시뮬레이션 또는 T2 벤더 수치를 fact로 라벨링                          | <code>relabel</code>                 | <code>insufficient</code> |
| R5    | LLM 판사 (gpt-4o) | 주장 문장과 원문 스니펫 간의 <b>사실적 불일치/모순</b>                               | <code>re_extract</code>              | <code>rejected</code>     |

### ■ 재시도 예산(최대 2회) 및 종결 상태의 분리 원칙

- **에이전트 단위 재시도 카운팅**: 한 번의 감사 패스에서 특정 에이전트의 주장이 여러 개 적발되더라도 해당 에이전트의 `retry_count` 는 1회만 증가하여 기회를 보장합니다.
- **근거 불충분(insufficient)과 사실 왜곡(rejected)의 분리**:
  - `insufficient` : 추가 조사를 통해서도 유의미한 근거를 찾지 못한 상태 (결론에서 제외하고 한계점에 기록).
  - `rejected` : R5 판사 결과 원문 내용과 주장이 정면으로 충돌하여 사실이 아닌 것으로 판명된 상태 (영구 기각).
- **종결 상태 격리**: 종결된 주장은 차기 감사 루프에서 제외되어 무한 루프 진입을 방지합니다.

## 07 Dual TRL 성숙도 합성 및 리포트 전달 체계

### ■ 연구 성숙도와 생태계 성숙도를 분리하는 Dual TRL 프레임워크

시뮬레이션 중심의 신기술과 오픈소스 기반의 기성 기술을 단순 단일 척도로 평가하면 성숙도의 착시가 발생합니다. 본 시스템은 **개별 기술 자체의 연구 성숙도 (tech\_trl)**와 **산업 계열의 시장 도입 생태계 성숙도(family\_trl)**를 엄격히 분리 산출합니다.

### ■ Dual TRL 산출 및 신뢰도 판정 매핑 규칙

| 검증된 근거 유형 (Status == 'ok')        | 개별 기술 TRL (tech_trl) | 계열 생태계 TRL (family_trl) | 산출 근거 및 의미                                     |
|-----------------------------------|----------------------|-------------------------|------------------------------------------------|
| 연구 관점 <b>fact</b> (실측 데이터)        | TRL 5-6              | —                       | 실제 하드웨어/GPU 환경에서 오픈소스 또는 프로토타입 실증 완료.          |
| 연구 관점 <b>simulation</b> (시뮬레이션)   | TRL 3-4              | —                       | 실물 칩이 아닌 사이클 단위 하드웨어 시뮬레이터 연구 검증 단계.           |
| 도입 관점 <b>fact</b> (상용 배포)         | —                    | TRL 7-8                 | 산업계 표준 프레임워크 또는 주요 CSP에서 실제 상용 운영 중.           |
| 도입 관점 <b>vendor_claim</b> (벤더 발표) | —                    | TRL 6-7                 | 주요 제조사(Samsung, Intel 등)의 로드맵 발표 및 프로토타입 데모.   |
| 검증된 근거 없음                         | Unknown              | Unknown                 | 근거 불충분(Insufficient Evidence)으로 신뢰도 'none' 부여. |

### ■ KIVI vs CXL-PNM 성숙도 간극 평가 결과

#### KIVI (SW) | tech: 5-6, family: 7-8 (신뢰도: high)

- **연구 성숙도:** 오픈소스(PyTorch/CUDA) 기반 실측 구현 단계(TRL 5-6).
- **생태계 성숙도:** KV 양자화 기법은 이미 vLLM, TensorRT-LLM 등에 널리 채택(TRL 7-8).
- **핵심 시사점:** 단기 적용성이 뛰어나나 2-bit 극단 양자화 시 정확도 검증 필요.

#### CXL-PNM (HW) | tech: 3-4, family: 7-8 (신뢰도: high)

- **연구 성숙도:** 7nm 공정 기반 사이클 단위 시뮬레이션 연구 단계(TRL 3-4).
- **생태계 성숙도:** CXL 메모리 풀링 자체는 대형 벤더 주도로 상용화 진입(TRL 7-8).
- **핵심 시사점:** 기술과 계열 간의 성숙도 간극이 뚜렷하며, 장기 하이브리드 결합 유망.

### ■ Jinja2 템플릿 조립 및 한글 지원 PDF 자동 변환

- **Jinja2 보고서 조립:** `src/synthesis/templates/report.md.j2` 템플릿을 통해 본문 Citation 번호와 References 출처 목록을 1:1로 자동 연동합니다.
- **Strict Grounding Polishing:** `OPENAI_API_KEY` 설정 시 `gpt-4o` 가 문맥을 정제하되, 수치·TRL·주장ID·승자부제 불변식을 절대 훼손하지 않습니다.
- **xhtml2pdf 한글 임베딩:** `src/synthesis/pdf_export.py` 가 프로젝트 내 나눔고딕(NanumGothic) 또는 시스템 폰트를 자동 탐색하여 깨짐 없는 PDF를 생성합니다.

08 테스트 전략, 안전 변경 경계 및 운영 관리

■ 모듈 인벤토리가 아닌 시스템 계약(Contract) 중심 테스트 스위트

본 시스템의 테스트 스위트는 외부 의존성(Tavily API, OpenAI API)을 모의(Mock) 객체로 격리하여 **100% 오프라인 환경에서도 결정론적 검증이 가능**하도록 설계되었습니다. 변경 작업 시 보호해야 할 불변식을 기준으로 안전 변경 경계를 정의합니다.

■ 시스템 안전 변경 경계 매트릭스 (Safe Change Matrix)

| 변경 대상 영역      | 최우선 검증 테스트 파일                                       | 보호해야 할 핵심 불변식 (Invariants)                                    |
|---------------|-----------------------------------------------------|---------------------------------------------------------------|
| State 키 및 리듀서 | tests/test_state.py                                 | 14개 키 불변, ID 기준 역등 병합, URL 기준 출처 중복 제거 및 외래키 보존.              |
| 그래프 라우팅 & 루프  | tests/test_graph.py                                 | 병렬 Fan-out, 단일 감사 Fan-in, 시장→이해관계자 연쇄, 2회 상한 수렴.              |
| 감사 규칙 & 판사    | tests/test_audit.py                                 | R1~R4 정적 룰 격리, R5 판사 사실성 심사, 종결 상태(insufficient/rejected) 확정. |
| 논문 RAG 및 청킹   | tests/test_rag.py                                   | 섹션 인지형 청킹 보존, 충분성 게이트, 연속 3문장 원문 발췌, 대역폭 축 보존.                |
| 웹 검색 & 출처     | tests/test_research.py                              | T1~T4 티어 분류, 지지/반박 쌍 검색, 4대 액터 슬롯 보존, mock 격리.                |
| TRL 및 보고서 PDF | tests/test_synthesis.py<br>tests/test_pdf_export.py | Dual TRL 분리 매핑, 승자 부재 원칙, 한글 폰트 탐색 및 유효 PDF 생성.               |

■ 현업 운영 트러블슈팅 4단계 가이드

CASE 01. 논문 원문 근거 누락 또는 FAISS 인덱스 오류

RESOLVED

1. 증상  
논문 분석 Claim이 모두 insufficient로 산출됨

2. 원인  
data/papers/ 미존재 또는 로컬 FAISS 인덱스 깨짐

3. 조치  
kivi.pdf, cxi\_pnm.pdf 확인 후 색인 재 구축 명령 실행

4. 검증  
python -m src.rag.indexer  
종료코드 0 확인

CASE 02. PDF 산출물 누락 및 Markdown 폴백 발생

RESOLVED

1. 증상  
final\_evaluation\_report.md만 생성 되고 PDF 없음

2. 원인  
xhtml2pdf 의존성 부재 또는 한글 폰트 탐색 실패

3. 조치  
data/fonts/NanumGothic.ttf 확인 및 라이브러리 점검

4. 검증  
pytest tests/test\_pdf\_export.py  
통과 확인